

Actividad 5

Regresión lineal simple, múltiple y logística

Análitica de datos y herramientas de inteligencia artificial

19 de octubre de 2026

Arantza Saraí Pérez Jiménez

A01738004

Reporte de resultados sobre el archivo Datos_Complementarios_CLV.xlsx

Introducción

Este reporte resume los resultados obtenidos en el notebook de la Actividad 5. La base contiene el inventario de una distribuidora de productos dentales: 2951 productos con su código, nombre, marca, almacén, existencias y valor del inventario.

El objetivo es explicar el valor del inventario de cada producto. Para ello se hizo el preprocesamiento de los datos, un modelo de regresión lineal simple, un modelo de regresión lineal múltiple y dos enfoques de regresión logística (con reponderación de clases y oversampling, y con variables dicotómicas).

Descripción de la base

Variable	Tipo	Descripción
Artículo	Código numérico	Identificador del producto
Nombre del artículo	Texto	Nombre único de cada producto
Marca	Categórica	26 marcas; Vita concentra 1810 productos (61 %)
Almacén	Categórica	Un solo valor: Almacén General
Existencias	Numérica	Piezas en inventario. Media 27.6, mediana 7, máximo 1396
Valor del inventario	Numérica	Valor monetario. Media 23,051, mediana 2,340, máximo 3,644,807

La media muy por encima de la mediana en las dos variables numéricas indica distribuciones con cola larga a la derecha: la mayoría de los productos tiene pocas piezas y poco valor, y unos cuantos tienen cantidades enormes.

Primeras filas de la base

Artículo	Nombre del artículo	Marca	Existencias	Valor del inventario
5804	CAMEO PRESS INGOT BOX HT A2	Aidite	1396	431,773.71
5816	CAMEO PRESS INGOT BOX LT A1	Aidite	1043	316,841.19
5762	CAMEO MILL BLOCS BOX C14 HT B1	Aidite	893	326,871.85
212202	DIENTES HU TABLILLA ZAHN4ALL ANTERIOR SUPERIOR...	Huge	893	10,368.49
5819	CAMEO PRESS INGOT BOX LT A2	Aidite	857	264,454.69

Resumen estadístico

Estadístico	Existencias	Valor del inventario
Observaciones	2951	2951
Media	27.59	23,050.92
Desviación estándar	82.06	134,279.41
Mínimo	1	0
Percentil 25	3	1,053.28
Mediana	7	2,340.51
Percentil 75	15	6,180.99
Máximo	1396	3,644,807.19

La base tiene 26 marcas distintas, 2951 nombres de artículo únicos y un solo almacén. La desviación estándar es mucho mayor que la media en las dos variables, otra señal de la asimetría que se corrige con el logaritmo.

Preprocesamiento

Limpieza inicial

No se encontraron filas duplicadas. Se eliminaron el código y el nombre del artículo, porque solo identifican al producto y no miden nada, y el almacén, porque tiene un único valor y no aporta información. Quedaron tres columnas para el análisis: marca, existencias y valor del inventario.

Valores nulos

Ninguna columna tiene valores nulos, por lo que no fue necesario eliminar columnas ni imputar valores. En el código se dejó la regla de imputación (mediana para numéricas y moda para categóricas) por si la base se actualiza con datos incompletos.

Columna	Nulos	Porcentaje
Marca	0	0 %
Existencias	0	0 %
Valor del inventario	0	0 %

Transformación logarítmica

Ambas variables numéricas tenían una asimetría muy fuerte, por lo que se transformaron con el logaritmo natural de uno más el valor. Se usa uno más x porque el valor del inventario tiene mínimos de cero.

Variable	Asimetría original	Asimetría final
Existencias	7.213	0.766
Valor del inventario	16.601	0.286

La asimetría final ya está dentro de un rango aceptable para modelar. La asimetría final se midió después de tratar los outliers.

Outliers

Se aplicó el método del rango intercuartílico (IQR). En lugar de eliminar filas, los valores extremos se acotaron al límite más cercano para no perder registros.

Variable (en logaritmo)	Outliers detectados	Límite inferior	Límite superior
Existencias	138	-0.693	4.852
Valor del inventario	232	4.307	11.383

El límite superior de existencias equivale a unas 127 piezas, y los límites del valor del inventario equivalen aproximadamente a 73 y 87 mil. Después del tratamiento no quedó ningún outlier.

Figura 1. Boxplots antes (arriba) y después (abajo) de acotar los valores extremos.

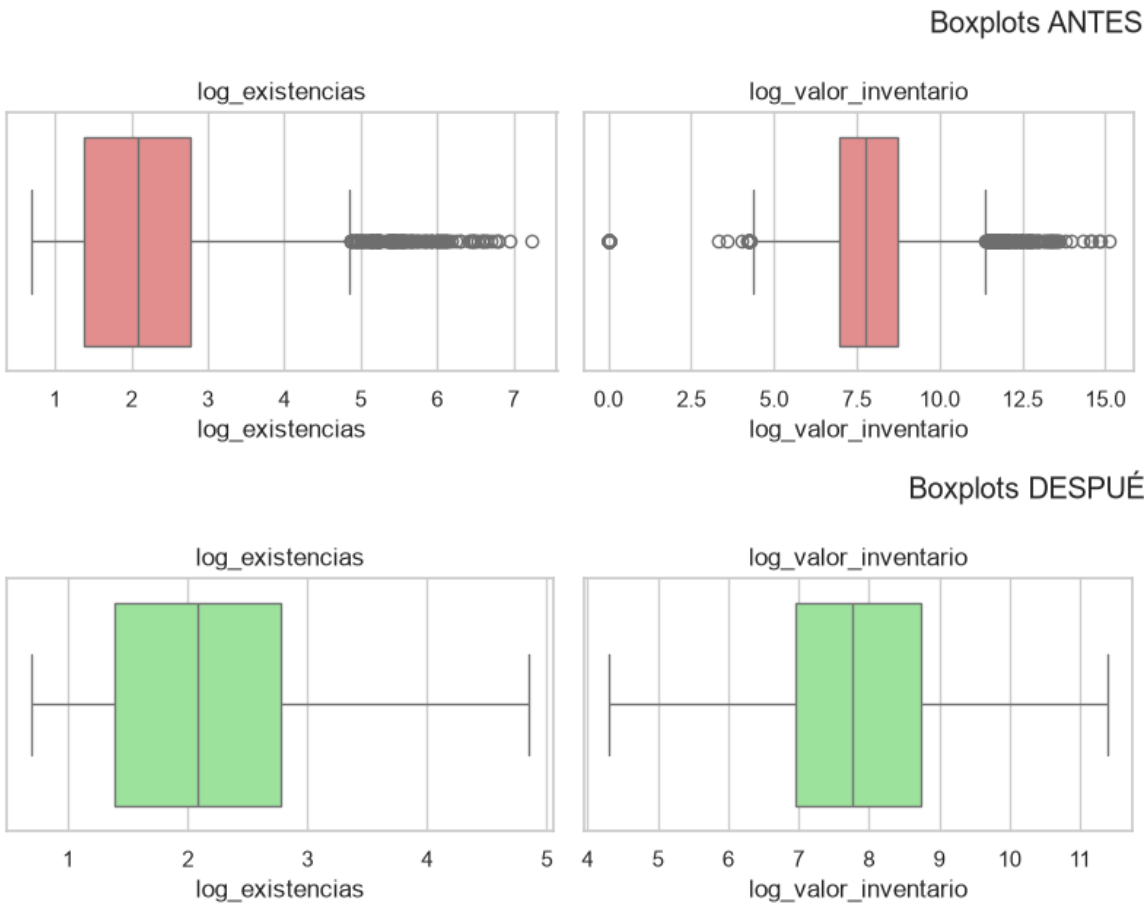
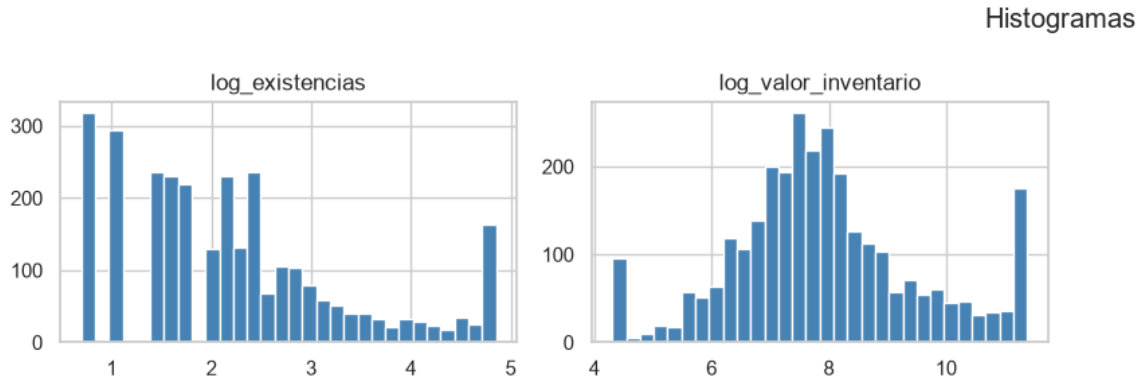


Figura 2. Distribución final de las dos variables numéricas.



El logaritmo del valor del inventario tiene forma parecida a una campana centrada cerca de 7.5. Las barras altas en los extremos corresponden a los valores acotados. El logaritmo de existencias sigue concentrado en valores bajos, porque la mayoría de los productos tiene pocas piezas.

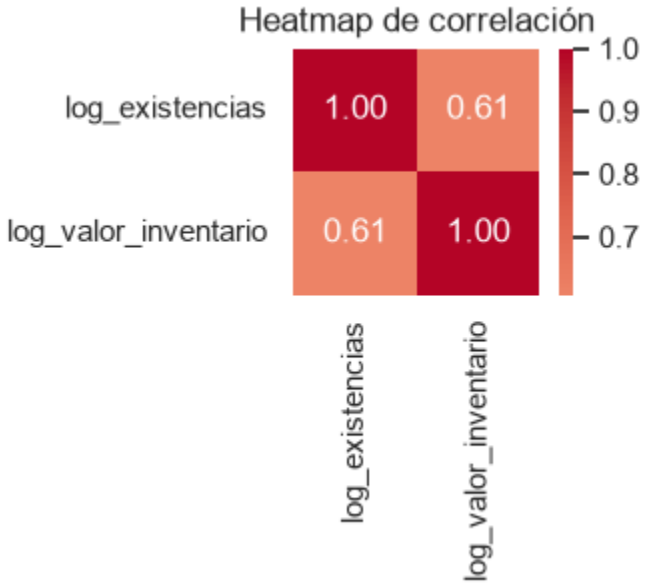
Regresión lineal simple

Análisis de correlación

Solo existen dos variables numéricas, así que la pareja con mayor correlación es el logaritmo de existencias con el logaritmo del valor del inventario.

Variable 1	Variable 2	Correlación de Pearson
Logaritmo de existencias	Logaritmo del valor del inventario	0.607

Figura 3. Mapa de calor de la correlación de Pearson.



La correlación de 0.607 es positiva y de intensidad moderada. Las existencias explican una parte importante del valor, pero no todo; falta el precio unitario, que no está en la base.

Modelo

Se ajustó un modelo de mínimos cuadrados ordinarios con el logaritmo del valor del inventario como variable dependiente.

Ecuación: logaritmo del valor = 5.9981 + 0.8677 por el logaritmo de existencias

Parámetro	Coeficiente	Error estándar	Estadístico t	p-value	Intervalo de confianza 95 %
Constante	5.9981	0.052	115.214	menor a 0.001	5.896 a 6.100
Logaritmo de existencias	0.8677	0.021	41.472	menor a 0.001	0.827 a 0.909

Medida de ajuste	Valor
R cuadrado	0.368
R	0.607
Estadístico F	1720
AIC	9813
Observaciones	2951

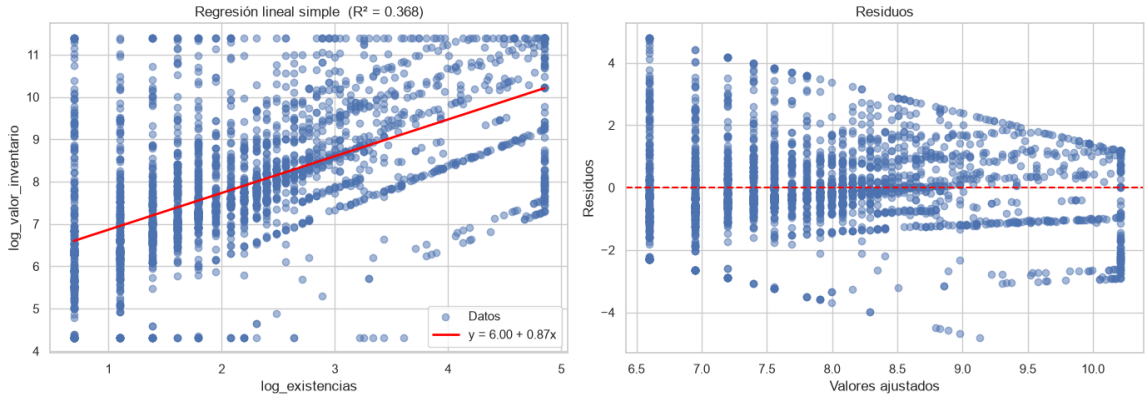
Diagnóstico de los residuos del modelo simple:

Prueba	Valor	Lectura
Omnibus	217.157 (p menor a 0.001)	Los residuos no son perfectamente normales
Jarque-Bera	512.037 (p menor a 0.001)	Confirma la falta de normalidad
Asimetría de residuos	0.447	Cola ligera a la derecha
Curtosis	4.834	Colas algo más pesadas que la normal
Durbin-Watson	1.361	Autocorrelación leve, la base viene ordenada por existencias
Número de condición	6.25	Sin problemas numéricos
Log-verosimilitud	-4904.5	

Prueba	Valor	Lectura
BIC	9825	
p-value del estadístico F	1.44e-296	Modelo globalmente significativo

Como las dos variables están en logaritmo, el coeficiente se interpreta como una elasticidad: si las existencias aumentan 1 %, el valor del inventario aumenta cerca de 0.87 %. Las existencias explican alrededor del 37 % de la variación del valor.

Figura 4. Recta de regresión sobre los datos (izquierda) y residuos contra valores ajustados (derecha).



En la gráfica de la izquierda los puntos forman líneas diagonales. Cada línea corresponde a productos con un precio unitario fijo, porque con precio fijo el valor crece proporcionalmente con las piezas. Productos con precios distintos quedan en líneas distintas, y una recta única no puede capturarlo. En los residuos la dispersión es mayor con valores ajustados bajos y se reduce hacia la derecha, así que la varianza no es constante. La prueba de Jarque-Bera indica que los residuos no son perfectamente normales (asimetría 0.45 y curtosis 4.8).

Regresión lineal múltiple

Construcción del modelo

Se partió de las existencias y de una columna 0 o 1 por cada marca. El modelo se depuró en dos pasos:

- Multicolinealidad: se eliminó la marca Vita por tener un VIF de 233.8.
- Eliminación hacia atrás: se quitaron por no ser significativas las marcas Scheftner (p = 0.845), Parmex (p = 0.134), Dess (p = 0.105) y Schick (p = 0.092).

La marca de referencia que quedó fuera de las columnas desde el inicio es 3Dgar. Las marcas eliminadas (Vita, Scheftner, Parmex, Dess y Schick) pasan a formar parte de ese grupo de referencia, de modo que cada coeficiente de marca se lee como la diferencia frente a ese grupo. El modelo final tiene 21 variables explicativas, todas significativas, y un VIF máximo cercano a 1.5.

Coeficientes del modelo final

Variable	Coeficiente	Error estándar	p-value
Constante	5.4148	0.045	menor a 0.001
Logaritmo de existencias	0.9620	0.019	menor a 0.001
Aidite	0.9896	0.077	menor a 0.001
Amann Girrbach	1.8784	0.059	menor a 0.001
Anax Dent	1.1797	0.100	menor a 0.001
Apple	3.9673	0.961	menor a 0.001
Arma Dental	1.8472	0.680	0.007
Asiga	2.1626	0.278	menor a 0.001
Creation	0.6780	0.066	menor a 0.001
Cyberpuerta	1.7259	0.679	0.011
Dekema	2.1686	0.393	menor a 0.001
Dentine	1.5511	0.481	0.001
Durr Dental	4.6581	0.680	menor a 0.001
Exocad	3.3817	0.430	menor a 0.001
Hass	1.4070	0.290	menor a 0.001
Huge	-2.3520	0.115	menor a 0.001
Jensen	1.0499	0.150	menor a 0.001
Medit	2.9746	0.321	menor a 0.001
Phrozen	0.9622	0.197	menor a 0.001
Quatro	2.4799	0.481	menor a 0.001
Renfert	2.9298	0.364	menor a 0.001
Roko	1.8841	0.340	menor a 0.001

Medidas de ajuste y diagnóstico del modelo múltiple:

Medida	Valor
R cuadrado	0.644
R cuadrado ajustado	0.642

Medida	Valor
Estadístico F	252.8 (p menor a 0.001)
Grados de libertad del modelo	21
Grados de libertad de los residuos	2929
Log-verosimilitud	-4056.6
AIC	8157
BIC	8289
Omnibus	294.54
Jarque-Bera	2295.28
Asimetría de residuos	0.003
Curtosis	7.321
Durbin-Watson	1.477
Número de condición	144

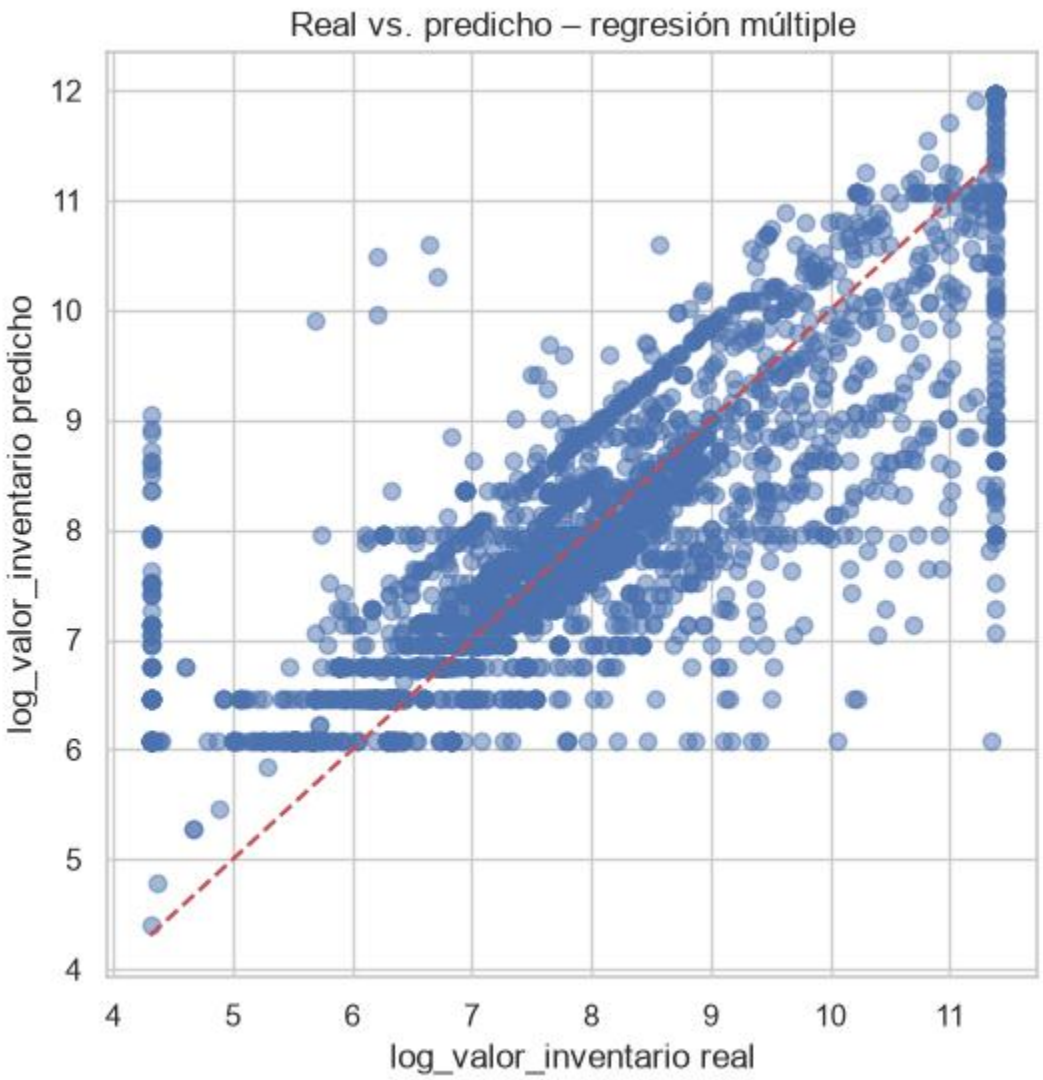
Las marcas con los coeficientes más altos son Durr Dental (4.66), Apple (3.97) y Exocad (3.38). Huge es la única con coeficiente negativo (-2.35), lo que indica productos de muy bajo valor unitario frente al grupo de referencia. Los residuos siguen sin ser normales (curtosis de 7.3), pero la asimetría es casi cero y el Durbin-Watson de 1.48 es aceptable.

Comparación contra el modelo simple

Medida	Modelo simple	Modelo múltiple
Constante	5.9981	5.4148
Coeficiente del logaritmo de existencias	0.8677	0.9620
R cuadrado	0.3684	0.6445
R cuadrado ajustado	0.3682	0.6419
AIC	9813.0	8157.1
Variables explicativas	1	21

El coeficiente de existencias aumenta 10.9 % al controlar por la marca, y se acerca a una relación proporcional. El R cuadrado ajustado casi se duplica y el AIC baja más de 1600 puntos, una mejora muy grande aun penalizando por tener más variables.

Figura 5. Valores reales contra valores predichos del modelo múltiple.



Los puntos siguen la diagonal en la parte central, lo que confirma que el modelo acierta en general. Las franjas horizontales abajo son productos de pocas piezas a los que el modelo asigna el mismo valor, y la columna vertical a la derecha corresponde a los valores acotados en el límite superior. Queda cerca de un 36 % de variación sin explicar, probablemente por la falta del precio unitario.

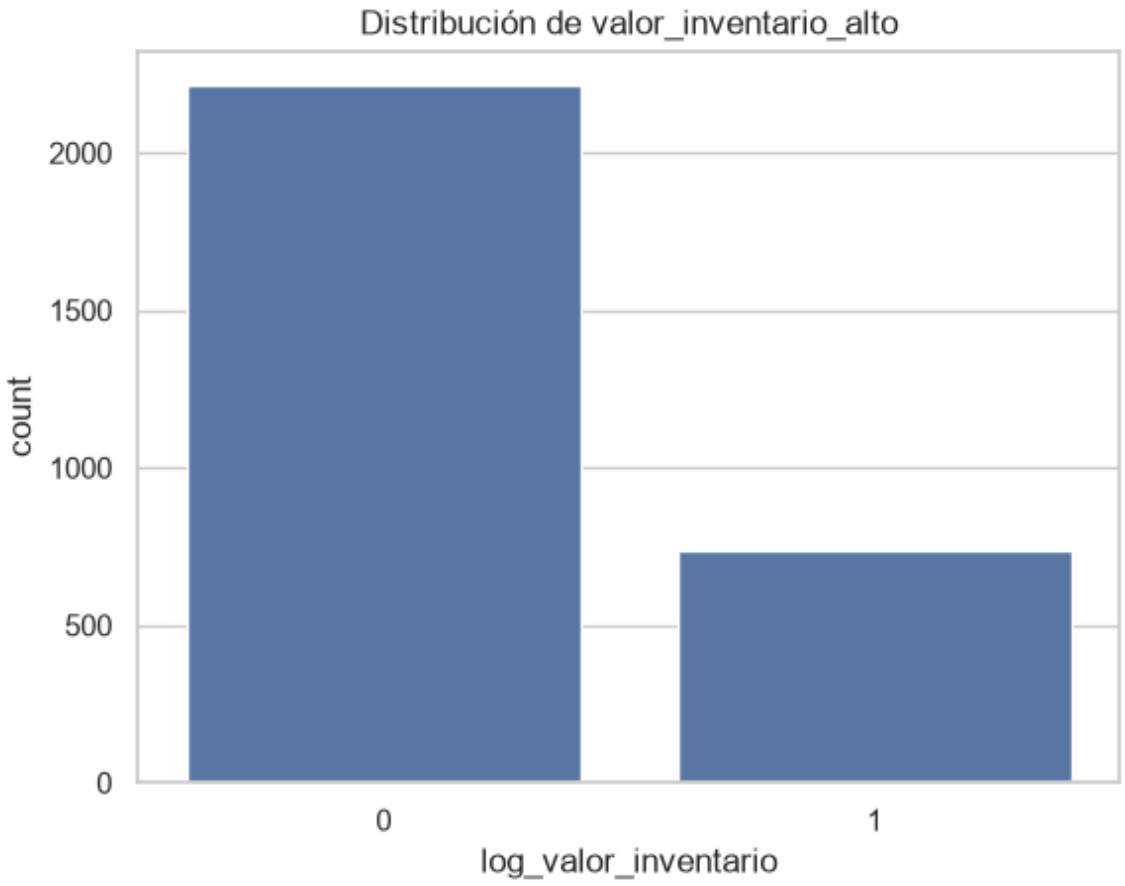
Regresión logística

Variable dicotómica

La base no trae una variable dicotómica, por lo que se creó valor_inventario_alto: vale 1 si el producto está en el 25 % superior de valor del inventario y 0 en caso contrario. El logaritmo del valor se excluyó de los predictores, porque de ahí sale la variable objetivo.

Clase	Productos	Porcentaje
0 (valor no alto)	2213	74.99 %
1 (valor alto)	738	25.01 %

Figura 6. Distribución de la variable dicotómica.



La proporción es de 3 a 1, justo el caso donde conviene reponderar las clases o hacer oversampling.

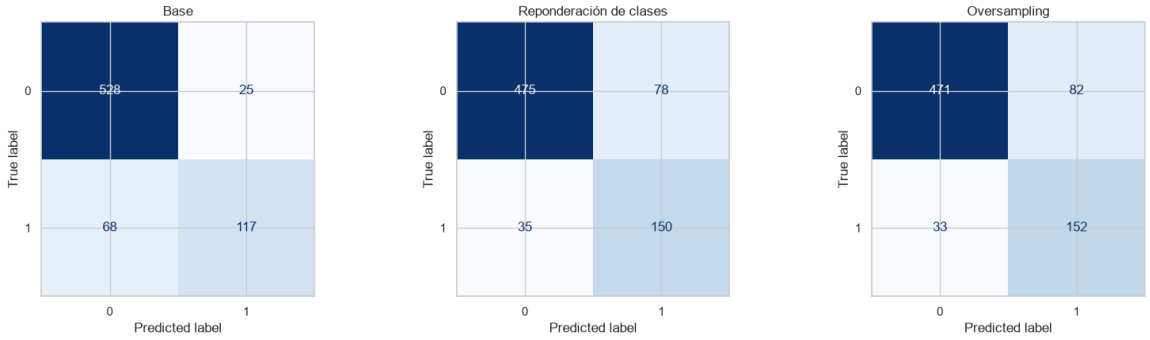
Reponderación de clases y oversampling

Se dividió la base en 75 % para entrenamiento y 25 % para prueba, conservando la proporción de clases. Las variables se estandarizaron. El oversampling se aplicó solo al entrenamiento: se repitieron al azar productos de la clase 1 hasta tener 1660 de cada clase.

Modelo	Accuracy	Precisión (clase 1)	Recall (clase 1)	F1 (clase 1)	AUC
Base	0.8740	0.8239	0.6324	0.7156	0.9074
Reponderación de clases	0.8469	0.6579	0.8108	0.7264	0.9084

Modelo	Accuracy	Precisión (clase 1)	Recall (clase 1)	F1 (clase 1)	AUC
Oversampling	0.8442	0.6496	0.8216	0.7255	0.9082

Figura 7. Matrices de confusión de los tres modelos sobre el conjunto de prueba.



El modelo base tiene el mejor accuracy, pero deja pasar más de un tercio de los productos de valor alto (recall de 0.632). Con reponderación y con oversampling el recall sube a 0.81 y 0.82, a cambio de menor precisión. El F1 mejora ligeramente y el AUC es casi idéntico en los tres, lo que indica que balancear solo mueve el punto de corte. Se eligió la reponderación de clases por tener el mejor F1 y no duplicar datos.

Variable estandarizada	Coeficiente	Odds ratio
Logaritmo de existencias	1.6181	5.04
Amann Girrbach	0.8341	2.30
Exocad	0.3423	1.41
Aidite	0.3417	1.41
Vita	-0.6426	0.53
Huge	-0.9065	0.40

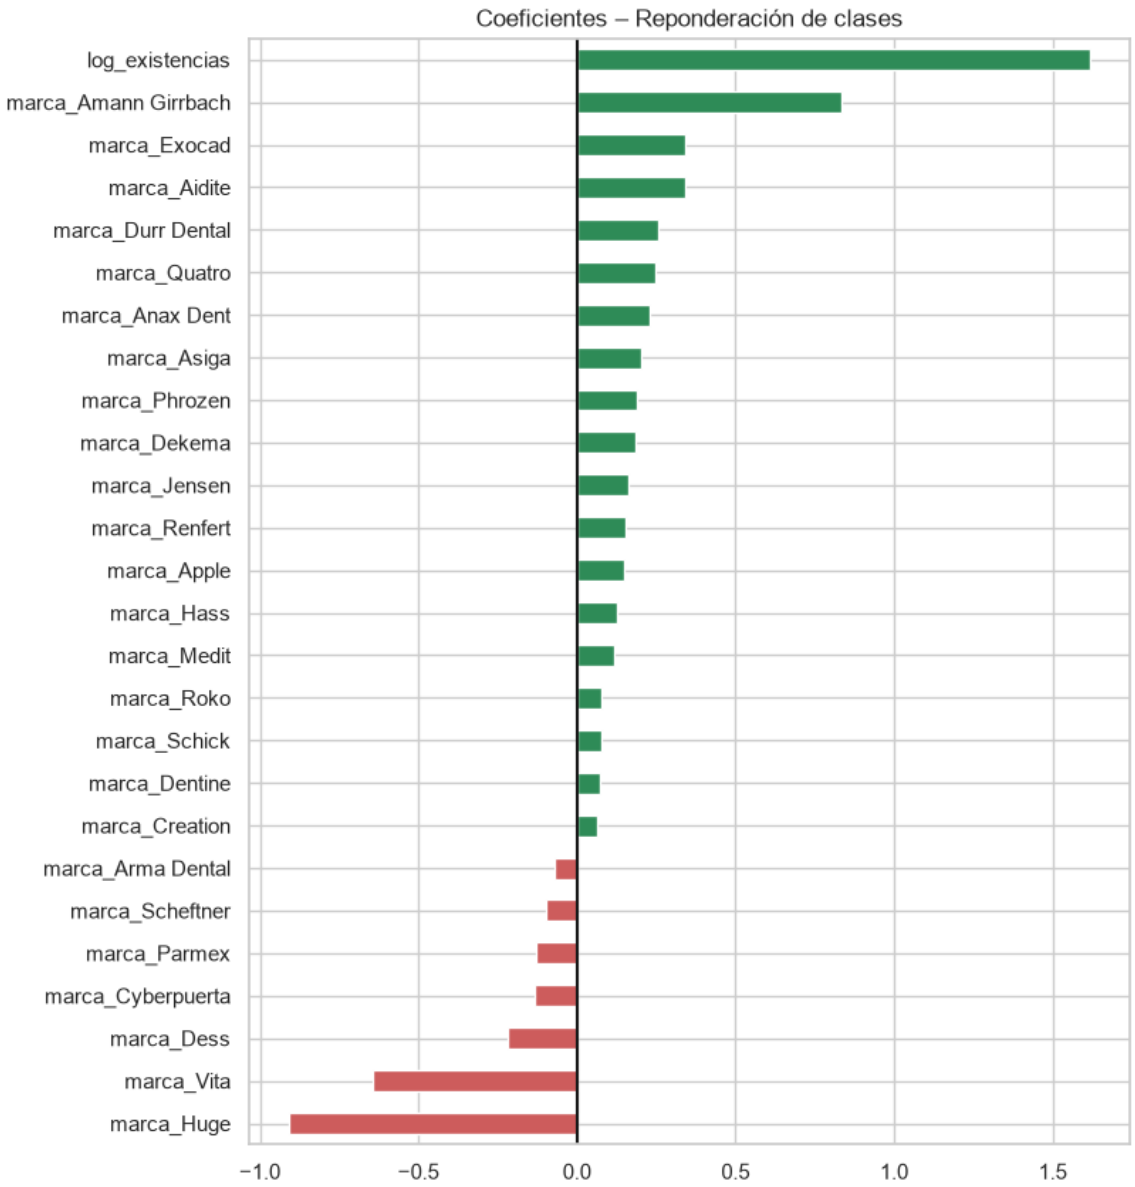
La tabla muestra las variables con mayor efecto del mejor modelo. El resto de las marcas tiene odds ratios entre 0.80 y 1.30.

Tabla completa de coeficientes del modelo con reponderación de clases (variables estandarizadas, ordenadas de menor a mayor):

Variable	Coeficiente	Odds ratio
Huge	-0.9065	0.4039
Vita	-0.6426	0.5259
Dess	-0.2194	0.8030
Cyberpuerta	-0.1341	0.8745

Variable	Coeficiente	Odds ratio
Parmex	-0.1292	0.8788
Scheftner	-0.0974	0.9072
Arma Dental	-0.0687	0.9336
Creation	0.0620	1.0639
Dentine	0.0738	1.0766
Schick	0.0759	1.0788
Roko	0.0781	1.0813
Medit	0.1188	1.1262
Hass	0.1270	1.1355
Apple	0.1481	1.1596
Renfert	0.1550	1.1677
Jensen	0.1613	1.1751
Dekema	0.1853	1.2036
Phrozen	0.1909	1.2104
Asiga	0.2019	1.2237
Anax Dent	0.2291	1.2575
Quatro	0.2472	1.2804
Durr Dental	0.2576	1.2939
Aidite	0.3417	1.4073
Exocad	0.3423	1.4082
Amann Girrbach	0.8341	2.3028
Logaritmo de existencias	1.6181	5.0433

Figura 8. Coeficientes del modelo con reponderación de clases.



Las existencias pesan bastante más que cualquier marca: un aumento de una desviación estándar multiplica por 5 los momios de que el producto sea de valor alto. Huge y Vita son las marcas que más reducen esa probabilidad, lo que coincide con el modelo múltiple.

Variables dicotómicas

Todas las variables explicativas se convirtieron a 0 o 1: las existencias valen 1 si superan su mediana, y cada marca se convirtió en una columna. Se obtuvieron 26 variables dicotómicas y se ajustó una regresión logística con pesos por clase.

Variable	Coeficiente	Odds ratio	Intervalo de confianza 95 %	p-value
Existencias por encima de la mediana	2.3610	10.60	8.22 a 13.68	menor a 0.001

Un producto con existencias altas tiene alrededor de 10.6 veces más momios de estar en el 25 % de mayor valor que uno con existencias bajas. Esta es la única variable con estimación estable. Las variables de marca presentan separación casi perfecta (coeficientes entre 19 y 47, errores estándar de decenas de miles y p-values de 1), porque hay marcas casi sin productos de valor alto, así que sus odds ratios no se pueden interpretar.

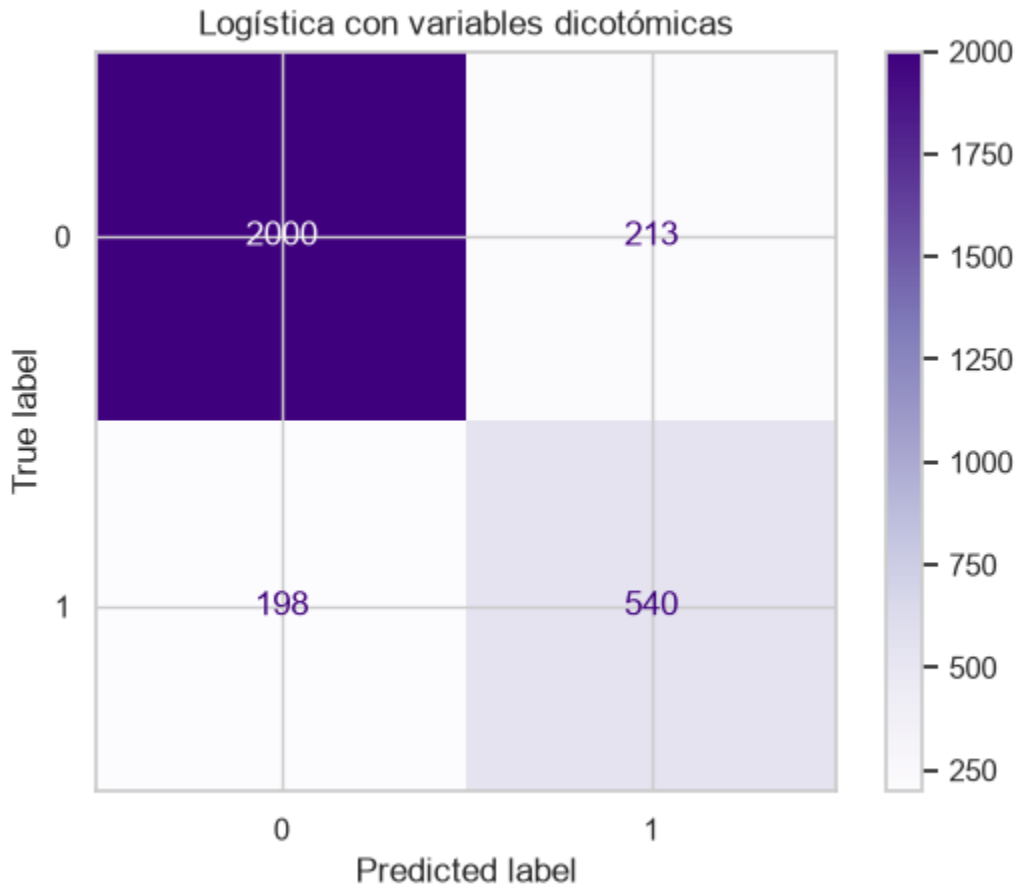
Resultado completo del modelo con variables dicotómicas. De las 26 variables, 25 tienen estimación inestable por separación y solo existencias altas es interpretable. Se incluyen todas para mostrar el resultado completo del ajuste (pseudo R cuadrado de Cox-Snell de 0.4436, log-verosimilitud de -1180.5, devianza de 2361.0).

Variable	Coeficiente	Error estándar	p-value
Constante	-23.5652	56,200	1.000
Existencias altas	2.3610	0.130	menor a 0.001
Aidite	24.4283	56,200	1.000
Amann Girrbach	24.6787	56,200	1.000
Anax Dent	23.4566	56,200	1.000
Apple	47.1313	79,500	1.000
Arma Dental	24.6633	56,200	1.000
Asiga	24.5303	56,200	1.000
Creation	22.1953	56,200	1.000
Cyberpuerta	-0.0009	88,800	1.000
Dekema	26.0746	56,200	1.000
Dentine	23.1101	56,200	1.000
Dess	-0.0009	68,800	1.000
Durr Dental	47.1313	68,800	0.999
Exocad	46.8157	61,000	0.999
Hass	24.4212	56,200	1.000
Huge	18.9796	56,200	1.000

Variable	Coeficiente	Error estándar	p-value
Jensen	23.2142	56,200	1.000
Medit	25.9195	56,200	1.000
Parmex	-0.0009	88,800	1.000
Phrozen	23.6290	56,200	1.000
Quatro	44.7702	62,800	0.999
Renfert	24.9510	56,200	1.000
Roko	23.9757	56,200	1.000
Scheftner	21.8380	56,200	1.000
Schick	24.0194	56,200	1.000
Vita	20.7691	56,200	1.000

Medida	Clase 0	Clase 1	Global
Precisión	0.91	0.72	
Recall	0.90	0.73	
F1	0.91	0.72	
Accuracy			0.86
AUC			0.891

Figura 9. Matriz de confusión del modelo con variables dicotómicas.



El AUC de 0.891 es bueno, aunque menor al 0.908 de los modelos con existencias continuas, porque al convertir las existencias a alto o bajo se pierde información. Estas métricas se calcularon sobre toda la base y no sobre datos de prueba, así que son algo más optimistas.

Conclusiones

- Las existencias son el factor más importante del valor del inventario, tanto en la regresión lineal como en la logística.
- El modelo lineal simple explica el 37 % de la variación del valor; al agregar la marca, el modelo múltiple llega al 64 %.
- El coeficiente de existencias pasa de 0.868 a 0.962 al controlar por la marca, casi una relación proporcional.
- Balancear las clases mejora la detección de productos de valor alto frente al modelo base, con una pequeña pérdida de precisión.
- Con variables dicotómicas, tener existencias por encima de la mediana multiplica por 10.6 los momios de que un producto sea de valor alto.

Limitaciones y recomendaciones

- La base no incluye el precio unitario de cada producto. Con esa variable el modelo explicaría casi todo el valor.
- Los residuos de los modelos lineales no son normales y su varianza no es constante, por lo que los intervalos de confianza deben tomarse como aproximados.
- Parte de los valores se acotaron en el límite superior, lo que genera acumulaciones de puntos en las gráficas.
- Para poder interpretar las marcas en la logística con variables dicotómicas, se recomienda agrupar las marcas con pocos productos en una sola categoría.